

YBIGTA hw 3-1


데이터 파악:

기본정보:

Data columns (total 5 columns):

#	Column	Non-Null Count	Dtype

0	sepal_length	150 non-null	float64
1	sepal_width	150 non-null	float64
2	petal_length	150 non-null	float64
3	petal_width	150 non-null	float64
4	species	150 non-null	object



해석: 종류별 petal length의 평균값을 차이가 난다. Setosa, Versicolor Species중에 이상치도 있는 것 같다. Variance within group으로 살펴보면, Setosa < Versicolor < Virginica를 관찰될 수 있다

각종 test

==== Shapiro-Wilk Test for 'petal length' ====
H0: Data follows Normal Distribution ($p > 0.05$)

Species	Statistic	P-Value	Result
setosa	0.9550	0.0548	Normal (H0 채택)
versicolor	0.9660	0.1585	Normal (H0 채택)
virginica	0.9622	0.1098	Normal (H0 채택)

결론: H0을 채택함으로, 데이터 'petal length' 변수는 정규성을 있다

==== Levene Test for 'petal length' ===

H0: 각 그룹(Species) 간 분산은 동일하다.

Variable | Statistic | P-Value | Result

petal_length | 19.4803 | 0.0000 | Not Equal (H0 기각)

결론: H0을 기각함으로, 데이터 'petal length' 변수가 그룹간의 분산성은 다른다, 앞 그림에서도 확인했다

==== ANOVA Hypothesis for 'petal length' ===

H0: 세 species 간 'petal_length'의 평균에는 차이가 없다. (모두 동일하다)

H1: 적어도 한 species의 'petal_length' 평균은 다른 species와 통계적으로 유의한 차이가 있다.

==== One-way ANOVA Results ===

Variable | F-Value | P-Value | Conclusion (alpha=0.05)

petal_length | 1180.1612 | 2.8568e-91 | H0 기각 (유의한 차이 있음)

결론: H0을 기각함으로, 데이터 'petal length' 변수가 그룹간의 평균값도 다르다, 앞 그림에서도 확인했다

====Tukey HSD (Scipy) for 'petal length'=====

Pairwise Group Comparisons (95.0% Confidence Interval)

Comparison	Statistic	p-value	Lower CI	Upper CI
(0 - 1)	-2.798	0.000	-3.002	-2.594
(0 - 2)	-4.090	0.000	-4.294	-3.886
(1 - 0)	2.798	0.000	2.594	3.002
(1 - 2)	-1.292	0.000	-1.496	-1.088
(2 - 0)	4.090	0.000	3.886	4.294
(2 - 1)	1.292	0.000	1.088	1.496

* Group Index Mapping:

Group 0: setosa

Group 1: versicolor

Group 2: virginica

[Significant Differences ($p < 0.05$)]

- setosa vs versicolor ($p=0.0000$) → 차이 있음
- setosa vs virginica ($p=0.0000$) → 차이 있음
- versicolor vs virginica ($p=0.0000$) → 차이 있음

결론: 세 그룹 간 평균값은 거로 다르다

결과 요약 (Conclusion)

분석 결과, 세 Species 간의 Petal Length는 모두 통계적으로 유의미한 차이가 있습니다.

1. 크기 순서 평균값을 기준으로 꽃잎 길이는 다음 순서대로입니다.

Virginica > Versicolor > Setosa

(ingroup variance는 반대로)

2. 통계적 근거

ANOVA: P-value < 0.05로 귀무가설이 기각되어, 세 그룹 중 적어도 하나는 차이가 있음을 확인했습니다.

사후검정 (Tukey HSD): 모든 조합에서 유의미한 차이(Reject H0)가 확인되었습니다. 즉, 세 그룹은 서로 명확하게 구분되는 집단입니다.

Boxplot: 시각적으로 세 그룹의 분포(Box)가 겹치지 않고 높이 차이가 뚜렷하게 나타납니다.

예측(회귀)

==== Regression Performance Metrics ===

MSE (Mean Squared Error): 0.1300 (낮을수록 좋음)

R2 Score (결정계수) : 0.9603 (높을수록 좋음)

==== Regression Coefficients ===

Intercept (절편): -0.2622

Feature Coefficient

0 sepal_length 0.722815

1 sepal_width -0.635816

2 petal_width 1.467524

결과 분석:

모델이 전체 데이터 변동성의 약 96%를 설명하고 있음을 의미한다. 아주 좋은 성능이다.

Petal length는 Sepal length, Petal width와 양(+)의 상관관계를 갖고 있으며, Sepal width와는 음(-)의 상관관계가 있다.